

Asociación ecológica y dependencia probabilística

Orlando Almazán Gallardo

El índice de Jaccard y la asociación de especies

En los albores del siglo XX, el botánico suizo Paul Jaccard (1868–1944) buscaba cuantificar la asociación ecológica entre distintos tipos de flores. Para ello, realizaba recurrentemente experimentos en los que seleccionaba dos especies de flores —digamos, A y B— y, en distintas regiones de los Alpes, registraba cuántas veces aparecían ambas especies a la vez; cuántas veces aparecía una, pero no la otra; y cuántas veces no aparecía ninguna. Esta información puede organizarse en lo que, en el análisis de datos categóricos, se conoce como tablas de contingencia:

	B_1	B_2	
A_1	x_{11}	x_{12}	$x_{11} + x_{12}$
A_2	x_{21}	x_{22}	$x_{21} + x_{22}$
	$x_{11} + x_{21}$	$x_{12} + x_{22}$	n

Figura 1: Tabla de contingencia 2×2

Aquí, A_1 representa la ausencia de la especie A, A_2 la presencia de la especie A, B_1 la ausencia de B y B_2 la presencia de B. Así pues, x_{11} son las veces en que ambas especies estuvieron ausentes, x_{12} las veces en que estuvo ausente la especie A y presente B, y así sucesivamente. Además, a estas tablas se les suele añadir en los márgenes las sumas de conteos por filas y por columnas con la finalidad de contabilizar la cantidad de veces que, en total, pasa cada uno de los eventos A_1 , A_2 , B_1 y B_2 . El número n es simplemente el total de observaciones.

Con información de este tipo, Jaccard, en su artículo de 1901 “*Étude comparative de la distribution florale dans une portion des Alpes et du Jura*”, presentó una manera muy razonable de medir qué tan asociadas están las especies A y B : contar el número de coocurrencias (x_{22}) y dividirlo entre la suma de todas las veces en las que apareció al menos una de las especies ($x_{12} + x_{21} + x_{22}$). De este modo, definió el índice

$$J = \frac{x_{22}}{x_{12} + x_{21} + x_{22}}.$$

Si J es cercano a 1, quiere decir que las especies tienden a aparecer casi siempre de forma simultánea, es decir, están fuertemente asociadas. Si, por el contrario, J es cercano a 0, quiere decir que las especies usualmente no aparecen juntas, es decir, están débilmente asociadas. A este cociente se le conoce como **índice de Jaccard** y ha sido históricamente muy utilizado en la literatura ecológica cuando se busca determinar la asociación de dos especies o cuantificar el parentesco de biodiversidad entre dos regiones. Además, en la actualidad, este índice se emplea ampliamente en áreas de la informática y la ciencia de datos como una medida de similitud entre conjuntos.

Así como el índice de Jaccard, existe una vasta cantidad de índices cuyo objetivo, en el ámbito ecológico, es cuantificar la asociación de especies, ya sean animales o vegetales. En 1982, Zdeněk Hubálek recopiló, en su artículo titulado “*Coefficients of association and similarity, based on binary (presence-absence) data: an evaluation*”, un total de 43 índices diferentes, entre los cuales, además del de Jaccard, destacan los índices de Ochiai, Kulczynski, Dice, Simpson y Sokal–Sneath 2. Todos ellos, junto con una amplia cantidad más que han aparecido desde entonces, forman parte de lo que se conoce como **índices de asociación de especies**.

Desde un punto de vista estadístico, una pregunta inmediata que surge al analizar este tipo de índices es si reflejan una “verdadera” dependencia probabilística. Por ejemplo, ¿es cierto que valores cercanos a 0 del índice de Jaccard implican necesariamente independencia estocástica, y viceversa? O, en términos más generales, ¿es cierto que la dependencia probabilística es equivalente a la noción de asociación ecológica? Para responder esta pregunta, primero debe definirse con precisión qué se entiende por independencia probabilística en este contexto.

Independencia probabilística (de especies)

Con la finalidad de estudiar las características estocásticas de una muestra de datos, desde la inferencia estadística paramétrica, primero debe especificarse el modelo de muestreo de dichos datos. Para tablas de contingencia, como la presentada anteriormente, el esquema de muestreo que suele utilizarse es el **multinomial** (aunque no es el único). Recuerde que esta distribución es una generalización de la binomial, solo que en vez de contar con dos posibles resultados (éxito/fracaso) el modelo multinomial considera múltiples resultados; en particular, en el caso de las tablas de contingencia 2×2 como la que se presentó anteriormente, se consideran 4 posibles: $A_1 \cap B_1$, $A_1 \cap B_2$, $A_2 \cap B_1$ y $A_2 \cap B_2$.

El parámetro de una distribución multinomial es el vector $\boldsymbol{\theta}$, que determina las probabilidades de cada uno de los posibles resultados. En este caso: $\boldsymbol{\theta} = (\theta_{11}, \theta_{12}, \theta_{21}, \theta_{22})$, donde $\theta_{ij} = P(A_i \cap B_j)$. Con esto en mente, la definición de independencia en este contexto surge de forma natural: los eventos A_i y B_j son independientes si se cumple que

$$P(A_i \cap B_j) = P(A_i)P(B_j).$$

O bien,

$$\theta_{ij} = \theta_{i\bullet} \theta_{\bullet j}, \quad \text{con } \theta_{i\bullet} = \sum_{j=1}^2 \theta_{ij} \text{ y } \theta_{\bullet j} = \sum_{i=1}^2 \theta_{ij}.$$

En términos de las especies, podría decirse que si se cumple lo anterior para cada una de las celdas de la tabla entonces la ausencia o presencia de la especie A es independiente de la ausencia o presencia de la especie B . O en términos más sencillos: las especies A y B son (probabilísticamente) independientes.

Ahora bien, para determinar si una tabla de contingencia presenta el patrón de independencia puede plantearse el siguiente contraste de hipótesis:

$$H_0 : \theta_{ij} = \theta_{i\bullet} \theta_{\bullet j} \quad \forall i, j \in \{1, 2\}$$

$$H_1 : \text{modelo sin restricciones sobre } \boldsymbol{\theta}.$$

Existen diversos métodos para llevar a cabo este contraste. En particular, desde la perspectiva Bayesiana, un posible método —que personalmente

aprendí de mi asesor de tesis, el Dr. Manuel Mendoza— es construir intervalos de máxima densidad para los términos

$$\omega_{ij} := \theta_{ij} - \theta_{i\bullet} \theta_{\bullet j}$$

vía simulación. Note que si $\omega_{ij} = 0$ se tendrá que $\theta_{ij} = \theta_{i\bullet} \theta_{\bullet j}$, por lo cual, si el 0 pertenece a cada uno de los intervalos, no habría evidencia para rechazar H_0 . En resumen, el procedimiento es el siguiente: primero se propone una distribución *a priori* para el vector $\boldsymbol{\theta}$. En la literatura estadística suele utilizarse una distribución Dirichlet (generalización de la Beta), pues resulta conjugada bajo el muestreo multinomial (i.e. si la distribución *a priori* es Dirichlet entonces la distribución posterior vuelve a ser Dirichlet). En particular, puede recurrirse a una Dirichlet cuyos parámetros sean todos 0.5, ya que corresponde a la distribución mínimo-informativa de Jeffreys. Luego, se calcula la distribución posterior de $\boldsymbol{\theta}$. Si se utiliza la Dirichlet de Jeffreys, se obtiene, mediante el Teorema de Bayes, que

$$P(\boldsymbol{\theta} \mid \underline{X}_{(1)}) = \text{Dir}(\boldsymbol{\theta} \mid x_{11} + 0.5, x_{12} + 0.5, x_{21} + 0.5, x_{22} + 0.5).$$

Una vez se tiene esta distribución, se simulan T realizaciones de ella $\{\boldsymbol{\theta}^{(s)}\}_{s=1}^T$ y se calcula ω_{ij} para cada una de estas simulaciones. Con esto, se obtiene una muestra simulada $\{\omega_{ij}^{(s)}\}_{s=1}^T$ para cada par de i, j . Finalmente, se construyen las distribuciones de cada ω_{ij} y se calculan numéricamente los intervalos de máxima densidad. Si el 0 pertenece a todos los intervalos entonces se decide no rechazar la hipótesis nula de independencia.

Algo interesante de las tablas de contingencia 2×2 es que si el patrón de independencia se cumple en una celda, entonces necesariamente se cumple en las otras tres (esto puede demostrarse algebraicamente de manera muy sencilla). Por ello, para llevar a cabo este contraste solo se necesita construir un intervalo de máxima densidad (por ejemplo, para ω_{11}).

Otro método Bayesiano para contrastar la hipótesis fue propuesto por Dennis Lindley en 1964. En él se define el término

$$\psi := \ln \left(\frac{\theta_{11} \theta_{22}}{\theta_{12} \theta_{21}} \right),$$

que, bajo independencia, cumple que $\psi = 0$. Así pues, la hipótesis nula puede reformularse como

$$H_0 : \psi = 0.$$

Por medio del Método de Laplace, Lindley consigue una aproximación normal de la distribución posterior de ψ :

$$P(\psi \mid \underline{X}_{(1)}) \approx N\left(\psi \mid \ln\left(\frac{x_{11}x_{22}}{x_{12}x_{21}}\right), \frac{1}{x_{11}} + \frac{1}{x_{12}} + \frac{1}{x_{21}} + \frac{1}{x_{22}}\right).$$

Definiendo $\hat{\psi} := \ln\left(\frac{x_{11}x_{22}}{x_{12}x_{21}}\right)$ y $V := \frac{1}{x_{11}} + \frac{1}{x_{12}} + \frac{1}{x_{21}} + \frac{1}{x_{22}}$ puede obtenerse que

$$\frac{\psi \mid \underline{X}_{(1)} - \hat{\psi}}{\sqrt{V}} \sim N(0, 1).$$

Con esta distribución puede obtenerse fácilmente un intervalo de probabilidad para ψ de la misma forma que se construyen los intervalos de confianza en el ámbito frecuentista:

$$\left[\hat{\psi} - Z_{(1-\alpha/2)}\sqrt{V}, \hat{\psi} + Z_{(1-\alpha/2)}\sqrt{V} \right].$$

donde α es el nivel de significancia. Al igual que antes, si el 0 pertenece al intervalo entonces no se rechaza la independencia.

Para los escépticos del paradigma Bayesiano, desde el punto de vista frecuentista también existen métodos para contrastar la hipótesis de independencia. Dos muy populares son la prueba exacta de Fisher (que se usa particularmente para muestras pequeñas) y la prueba Ji-cuadrada de Pearson. En esta última se construye, mediante el Teorema del Límite Central, el estadístico de prueba

$$Q = \sum_{i=1}^2 \sum_{j=1}^2 \frac{(n x_{ij} - x_{i\bullet} x_{\bullet j})^2}{n x_{i\bullet} x_{\bullet j}},$$

que, bajo H_0 , sigue una distribución asintóticamente Ji-cuadrada con un grado de libertad. Fijando un nivel de significancia α , si con los datos se obtiene que $Q > \chi_{(1)(1-\alpha)}^2$ entonces se rechaza H_0 .

¿Dependencia probabilística equivale a asociación ecológica?

Retomando los experimentos que dieron origen al índice de Jaccard, suponga que al comparar las especies florales de rosa y genciana alpinas se reportan los siguientes resultados:

	Ausencia de rosa	Presencia de rosa	
Ausencia de genciana	14	86	100
Presencia de genciana	87	813	900
	101	899	1000

Figura 2: Ausencia/Presencia de gencianas y rosas alpinas

Con esta información se obtiene un índice de Jaccard de $J = 0.8245$, lo cual sugiere una asociación (ecológica) alta entre ambas especies. Ahora bien, ¿qué indican los contrastes de la hipótesis de independencia (estocástica)?

Si se considera la distribución a priori de Jeffreys para θ y la información proporcionada por la muestra, puede obtenerse que la distribución posterior de θ es

$$P(\theta \mid \underline{X}_{(1)}) = \text{Dir}(\theta \mid 14.5, 86.5, 87.5, 813.5).$$

Con ella, y tomando $T = 100,000$ simulaciones del vector θ , se obtiene la siguiente distribución de $\omega_{11} = \theta_{11} - \theta_{1\bullet}\theta_{\bullet 1}$:




Figura 3: Distribución posterior de ω_{11}

Cuya media es 0.0042 y su intervalo de máxima densidad al 95 % es $[-0.0021, 0.0106]$. Como el 0 pertenece al intervalo, no hay evidencia suficiente para rechazar la independencia.

En cuanto al contraste que propone Lindley, con la información de los datos se obtiene la siguiente distribución posterior aproximada para ψ :

$$P(\psi \mid \underline{X}_{(1)}) \approx N(\psi \mid 0.4195, 0.0958)$$

Estandarizando y fijando un nivel de significancia $\alpha = 0.05$, puede obtenerse el siguiente intervalo de probabilidad: $[-0.1870, 1.0261]$. Nuevamente el 0 pertenece a él, por lo que no hay evidencia para rechazar H_0 con este método.

Finalmente, realizando la prueba frecuentista de Pearson, se obtiene que el estadístico de prueba, ya evaluado con los datos, es

$$Q = 1.8613$$

que no excede el cuantil al nivel 0.95 de la Ji-cuadrada con un grado de libertad (3.8415). Por lo cual, tampoco con este método se obtienen criterios para rechazar la independencia en el modelo.

Así pues, a pesar de que se presentó un índice de Jaccard elevado, ello no implica una dependencia probabilística considerable. Construir datos que cumplan estas condiciones no es complicado. Con un poco de suspicacia, el lector podrá darse cuenta del truco: si la celda x_{22} es considerablemente más grande que las demás, siempre se tendrá un índice de Jaccard cercano a 1, independientemente de cómo estén organizados los otros datos. Con ello, solo hace falta ver que en una celda se presente el patrón de independencia, es decir, que la proporción de esa celda sea aproximadamente igual al producto de las proporciones de los márgenes correspondientes. Por ejemplo, con los datos que se presentaron, note que

$$\frac{x_{11}}{1000} = 0.014,$$

que es aproximadamente igual al producto de

$$\frac{x_{11} + x_{12}}{1000} = 0.1 \quad \text{y} \quad \frac{x_{11} + x_{21}}{1000} = 0.101$$

(0.0101). Esta construcción asegura independencia probabilística aunada con un índice de Jaccard alto.

Con un razonamiento similar al anterior puede construirse una tabla de contingencia en donde se rompa el patrón de independencia y se tenga un

valor de Jaccard cercano a 0. Puede comprobarse que con los siguientes datos se rechaza la hipótesis de independencia (con los tres contrastes propuestos) y se tiene un valor de Jaccard pequeño (0.1).

	B_1	B_2	
A_1	900	50	950
A_2	40	10	50
	940	60	1000

Figura 4: Ejemplo de tabla de contingencia 2×2

Este ejemplo indica que tampoco se cumple que dependencia probabilística implique necesariamente asociación ecológica fuerte.

Es importante mencionar que solamente se está considerando al índice de Jaccard como medida de asociación ecológica. Como se mencionó anteriormente, existe una gran cantidad de índices que, cada uno a su manera, buscan cuantificarla. En la literatura ecológica, se utilizan diversos índices dependiendo de los objetivos del investigador. Aquí únicamente se utilizó el índice de Jaccard para ejemplificar un caso en donde la dependencia probabilística no es equivalente a la noción de asociación ecológica. Sin embargo, no se pretende que este índice sea la única forma de medir esta última.

Entonces, ¿con cuál nos quedamos?

Desde un punto de vista puramente estadístico, podría pensarse que la auténtica forma de cuantificar patrones de dependencia o asociación en un conjunto de datos es mediante modelos probabilísticos. Sin embargo, esta postura resulta incompleta. Así como existen críticas a los índices de asociación ecológica, también hay críticas válidas que hacer a los contrastes estadísticos.

Una crítica que puede hacerse a los índices de asociación es que es posible obtener niveles de asociación distintos dependiendo del índice que se utilice. Por ejemplo, puede demostrarse algebraicamente que el índice de Ochiai (que también va de 0 a 1) es siempre mayor que el índice de Jaccard (salvo en los extremos, donde son iguales). Así pues, dependiendo del índice que el investigador utilice puede obtener niveles mayores o menores de asociación

con el mismo conjunto de datos. Por ello, es importante siempre interpretar cuidadosamente qué está cuantificando el índice que se utilice y no solo reportar su valor como un indicador universal de asociación.

Por otra parte, los contrastes de hipótesis estadísticos tampoco están exentos de críticas. Quizá la principal es que son modelo-dependientes, es decir, se asume desde un inicio que los datos siguen cierta distribución. Por ejemplo, los contrastes que se presentaron anteriormente tienen como supuesto que los datos siguen una distribución multinomial, y esto no es necesariamente verdadero (si bien es cierto que es posible realizar pruebas de bondad de ajuste, éstas no aseguran con total certeza la distribución de un conjunto de datos). Además, un ecólogo podría argumentar, con razón, que los contrastes estadísticos no toman en cuenta el contexto ecológico de donde se toman los datos, cosa que un índice de asociación sí refleja. Por lo tanto, los contrastes estadísticos tampoco pueden tomarse como una verdad absoluta.

Esta aparente tensión entre asociación ecológica y dependencia estocástica es, en realidad, una diferencia de perspectiva. Cada metodología busca el objetivo común de medir niveles de relación con las herramientas disponibles en su campo. Al final de cuentas, toda esta discusión pone de manifiesto que determinar patrones de dependencia o asociación es algo sumamente complicado. Por ello, quizás, lo más sabio sea tomar en cuenta ambas posturas y establecer comparaciones con el fin de contar con la mayor información posible.

Referencias

- [1] De Cáceres, M., & Legendre, P. (2009). Associations between species and groups of sites: indices and statistical inference. *Ecology*, 90(12), 3566–3574.
- [2] Hubálek, Z. (1982). Coefficients of association and similarity, based on binary (presence–absence) data: an evaluation. *Biological Reviews*, 57(3), 669–689.
- [3] Lindley, D. V. (1964). The Bayesian analysis of contingency tables. *The Annals of Mathematical Statistics*, 35(4), 1622–1643.