



INSTITUTO TECNOLÓGICO AUTÓNOMO DE MÉXICO

REGRESIÓN AVANZADA

Proyecto final

Modelo de regresión para predecir desempeño en competencias de Powerlifting

Integrantes	Clave única
Orlando Almazán Gallardo	198046
Adrián Berrón Piña	198264
Ricardo Bravo Cruz	195506

Profesor:
Dr. Luis Enrique Nieto Barajas
21 de mayo de 2025

Índice

1. Introducción	2
2. Análisis exploratorio de datos	3
3. Modelos propuestos	8
3.1. Formulación de modelos	8
3.2. Comparación de modelos	12
4. Desempeño predictivo	13
4.1. Modelo 1 – Lognormal incluyendo todas las variables	13
4.2. Modelo 2 – Con edad al cuadrado e interacciones	14
4.3. Comparación de modelos	15
5. Análisis sobre el modelo óptimo	16
5.1. Interpretación de los coeficientes del modelo lognormal completo	17
6. Conclusión	20
7. Referencias	21

1. Introducción

Este proyecto tiene como objetivo desarrollar un modelo predictivo que estime el rendimiento en press de banca (bench press) de atletas de powerlifting durante competencias oficiales, a partir de diversas características individuales y de desempeño. Para ello, se cuenta con una base de datos (Reynolds, et. al, 2006) compuesta por 10856 registros (7370 hombres y 3486 mujeres) cada uno correspondiente a un levantador distinto, en la cual se incluyen tanto variables personales, como de rendimiento físico.

La matriz de diseño utilizada para la modelación incorpora los siguientes predictores: sexo, edad, peso corporal, tipo de equipo utilizado (clasificados en raw, wraps, single-ply y multi-ply), mejor marca en sentadilla (squat) y mejor marca en peso muerto (deadlift). La variable respuesta es el peso levantado en press de banca (bench press) durante una competencia, el cual se busca modelar como una función de los predictores mencionados. Así pues, las variables son:

$x_1 = \text{Sexo (Hombre o mujer)} \in \{0, 1\}$

$x_2 = \text{Categoría (Raw, Wraps, Single-ply, Multi-ply)} \in \{0, 1, 2, 3\}$

$x_3 = \text{Edad} \in \mathbb{N}$

$x_4 = \text{Peso corporal (kilogramos)} \in \mathbb{R}$

$x_5 = \text{Mejor marca en squat (kilogramos)} \in \mathbb{R}$

$x_6 = \text{Mejor marca en deadlift (kilogramos)} \in \mathbb{R}$

$y = \text{Mejor marca en press de banca (kilogramos)} \in \mathbb{R}$

El regresor Categoría se refiere al equipo que está permitido usarse dependiendo de la categoría de la competencia en la que el atleta se encuentre. Raw corresponde a la categoría en donde no está permitido utilizar equipo especializado, Wraps en la que solo está permitido utilizar rodilleras, Single-ply en la que se permite utilizar prendas hechas con un solo grosor y Multi-ply en la que se permite el uso de equipamiento hecho de múltiples capas de material reforzado.

Para obtener los modelos se utilizará un enfoque Bayesiano, mediante el cual se obtendrán distribuciones posteriores para cada parámetro de la regresión utilizando técnicas de muestreo MCMC. En una fase inicial se propondrán nueve modelos, de los cuales, basados en los criterios de DIC y pseudo R cuadrada, se elegirán a los mejores dos. Una vez seleccionados, en una segunda fase, se medirá su capacidad predictiva, utilizando métricas como el Error cuadrático medio y la correlación lineal entre valores reales y valores predichos, y se

decidirá cuál es el modelo más apropiado. Posteriormente, en una fase final, se realizará un análisis de este modelo óptimo. Así, el análisis busca no solo identificar un modelo preciso y confiable, sino también cuantificar cuál es su capacidad para predecir el rendimiento en bench press competitivo.

2. Análisis exploratorio de datos

Antes de proceder con la estimación de los modelos de regresión, es fundamental realizar un análisis exploratorio de datos que permita comprender la estructura general de la base, identificar patrones, relaciones entre variables y posibles valores atípicos. Este análisis proporcionará una visión preliminar del comportamiento de las variables involucradas, y contribuye a fundamentar las decisiones de modelado que se tomarán posteriormente.

Sexo	Categoría	Edad promedio	Peso promedio	Sentadilla promedio	Press banca promedio	Peso muerto promedio
Hombre	Raw	28.2	90.8	193	132	225
Hombre	Wraps	30.6	98.4	227	148	243
Hombre	Single-ply	32.2	92.4	246	168	242
Hombre	Multi-ply	37.0	105.0	298	195	255
Mujer	Raw	30.2	68.6	108	61.0	133
Mujer	Wraps	31.4	71.1	121	66.1	139
Mujer	Single-ply	29.1	66.4	149	85.9	149
Mujer	Multi-ply	35.8	71.5	176	101.0	162

Cuadro 1: Promedios por sexo y categoría de levantamiento

Esta tabla muestra los promedios de edad, peso corporal y marcas máximas en los tres levantamientos principales (sentadilla, press de banca y peso muerto) para atletas agrupados por sexo y categoría de equipo. Se observan varias tendencias consistentes con lo esperado en el contexto competitivo del powerlifting:

- **Edad:** En general, los atletas masculinos tienen una edad promedio ligeramente menor en categorías menos asistidas (Raw: 28.2 años) y mayor en las más asistidas (Multi-ply: 37.0 años). Esto podría reflejar que mientras más edad tiene la persona, mayor es su tendencia a utilizar más equipo, una posible razón es para proteger más su cuerpo.
- **Peso corporal:** A medida que se avanza de Raw a Multi-ply, tanto en hombres como en mujeres, el peso promedio tiende a incrementarse. Esto puede indicar que atletas más pesados tienden a competir en categorías

más asistidas, posiblemente debido a que el uso de equipo permiten levantar mayor peso, lo cual es atractivo para personas con mayor masa corporal.

■ **Rendimiento en levantamientos:**

- En todas las categorías, los hombres levantan más peso que las mujeres, lo cual es esperado debido a las diferencias fisiológicas entre ambos sexos.
- Dentro de cada sexo, el rendimiento en los tres levantamientos aumenta sistemáticamente desde Raw hasta Multi-ply, lo que podría reflejar la ventaja mecánica que proporciona el uso de equipo especializado.
- En particular, se observa que el incremento es más marcado en el press de banca y en la sentadilla, que son los levantamientos donde el equipo puede ofrecer mayor asistencia. Por ejemplo, en hombres, el promedio de bench press pasa de 132 kg en la categoría Raw a 195 kg en Multi-ply, lo cual es un aumento de más del 47 %.

- **Comparación entre géneros:** La diferencia absoluta entre hombres y mujeres es mayor en sentadilla y peso muerto, pero la diferencia en press de banca también es considerable. En la categoría Multi-ply, la diferencia de rendimiento entre hombres y mujeres alcanza 122 kg en sentadilla, 94 kg en press de banca, y 93 kg en peso muerto.

En resumen, esta tabla confirma que tanto el sexo como el tipo de equipo utilizado tienen un efecto claro sobre el rendimiento promedio en los tres levantamientos considerados, lo cual respalda su inclusión como variables explicativas en un posible modelo. Además, puede verse una correlación positiva entre los pesos que el atleta levanta en sentadilla y en peso muerto con sus pesos en press de banca, lo cual también sugiere su inclusión como variables predictoras.

A continuación se presenta un diagrama que resume la distribución del mejor levantamiento en press de banca por sexo y categoría.





Figura 1: Mejor bench press por sexo y categoría

En la Figura 1 se muestran las siguientes tendencias:


- **Diferencias por sexo:** En todas las categorías, los hombres presentan valores consistentemente mayores que las mujeres. Esta diferencia es más pronunciada en las categorías asistidas (Single-ply y Multi-ply).
- **Aumento progresivo del rendimiento:** A medida que se avanza de Raw a Multi-ply, se observa un incremento en los pesos en ambos sexos. Esto sugiere que el uso de equipo técnico especializado contribuye significativamente a mejorar el rendimiento en press de banca.
- **Dispersión:** Puede verse que los hombres presentan mayor dispersión para todas las categorías. Además, es notorio que en las categorías Single-ply y Multi-ply se presenta una mayor dispersión en ambos géneros.

- **Comparación media y mediana:** En varios grupos, la media se encuentra por encima de la mediana (especialmente en hombres), lo cual indica una asimetría a la derecha en la distribución. Esto puede deberse a algunos atletas con marcas inusualmente altas.

Las siguientes matrices de dispersión muestran las relaciones entre edad, peso corporal y los tres levantamientos principales.



(a) Hombres



(b) Mujeres

Figura 2: Matrices de correlación por sexo

En las gráficas anteriores, se destaca la forma de la distribución de la va-

riable *BestBenchKg*, la cual presenta una asimetría positiva considerable. Esta característica sugiere que un modelo Log-normal o uno Gamma podría ser más apropiado que uno Normal.

También puede verse que *BestBenchKg* presenta una alta correlación con las variables de *BestSquatKg* y *BestDeadliftKg* (coeficientes de 0.838 y 0.762, respectivamente en la población de mujeres). Esto podría generar un problema de colinealidad en el modelado, por lo cual podrían considerarse modelos que no tomen en cuenta estas variables, o solamente tomen en cuenta una de las dos.

Por otra parte, basado en la gráfica que se presentará a continuación, otro posible modelo sería considerar la edad al cuadrado como regresor. Esto debido a que la relación entre la variables de mejor bench press y edad parece ser cuadrática.




Figura 3: Relación entre edad y mejor levantamiento en bench press, diferenciada por sexo

3. Modelos propuestos

3.1. Formulación de modelos

Con base en la información que proporcionó el análisis exploratorio de datos pueden proponerse cuatro diferentes tipos de modelos, de los cuales pueden explorarse alternativas que dependen de los regresores a considerar:

- Modelos con distribución Lognormal
- Modelos con distribución Gamma
- Modelos con interacciones
- Modelos jerárquicos

El primer tipo de modelo, el Lognormal, parece ser una buena opción debido a la distribución de los datos de la variable *BestBenchKg* (sobre todo en la población femenina) tal como se mostró en la Figura 2.2. Una alternativa atractiva es utilizar un modelo Gamma, el cual también podría ajustarse de buena manera a los datos de esta variable.

El uso de un modelo con interacciones se justifica por la posibilidad de que el efecto de una variable explicativa sobre el rendimiento en press de banca dependa del nivel de otra variable. Por ejemplo, es razonable suponer que el efecto de la edad sobre el rendimiento podría diferir según el sexo del atleta, o que la influencia del equipo utilizado no sea constante para todas las edades.

El uso de un modelo jerárquico es motivado por la estructura de los datos, donde los atletas están agrupados en distintas categorías según el tipo de equipo utilizado. Estas categorías representan contextos distintos de competencia que pueden influir en la relación entre las variables predictoras y la variable de respuesta.

Aunado a lo anterior, debido a la alta correlación observada entre las variables *BestDeadlift* y *BestSquatKg* con la variable de interés *BestBenchKg* (lo que podría generar un problema de colinealidad) resulta razonable probar diferentes versiones del modelo que incluyan o excluyan estas dos variables. Además, dado que se encontró que la relación entre las variables *Edad* y *BestBenchKg* es cuadrática entonces resulta conveniente integrar un modelo que tenga la variable *Edad* al cuadrado.

Así pues, los modelos propuestos fueron los siguientes:

1. Lognormal sin squat ni deadlift

Modelo:

$$\log(Y_i) \sim \mathcal{N}(\mu_i, \sigma^2) \quad (1)$$

$$\mu_i = \beta_0 + \beta_{\text{edad}} \cdot \text{Edad}_i + \beta_{\text{peso}} \cdot \text{Peso}_i + \beta_{\text{sexo}}[\text{Sexo}_i] + \beta_{\text{cat}}[\text{Categoría}_i] \quad (2)$$

$$\hat{Y}_i = \exp(\mu_i) \quad (3)$$

Este modelo excluye los levantamientos de sentadilla y peso muerto.

2. Lognormal sin squat

Modelo:

$$\log(Y_i) \sim \mathcal{N}(\mu_i, \sigma^2) \quad (4)$$

$$\begin{aligned} \mu_i = \beta_0 + \beta_{\text{edad}} \cdot \text{Edad}_i + \beta_{\text{peso}} \cdot \text{Peso}_i + \beta_{\text{deadlift}} \cdot \text{Deadlift}_i \\ + \beta_{\text{sexo}}[\text{Sexo}_i] + \beta_{\text{cat}}[\text{Categoría}_i] \end{aligned} \quad (5)$$

$$\hat{Y}_i = \exp(\mu_i) \quad (6)$$

Este modelo considera el peso muerto pero excluye la sentadilla.

3. Lognormal sin deadlift

Modelo:

$$\log(Y_i) \sim \mathcal{N}(\mu_i, \sigma^2) \quad (7)$$

$$\begin{aligned} \mu_i = \beta_0 + \beta_{\text{edad}} \cdot \text{Edad}_i + \beta_{\text{peso}} \cdot \text{Peso}_i + \beta_{\text{squat}} \cdot \text{Squat}_i \\ + \beta_{\text{sexo}}[\text{Sexo}_i] + \beta_{\text{cat}}[\text{Categoría}_i] \end{aligned} \quad (8)$$

$$\hat{Y}_i = \exp(\mu_i) \quad (9)$$

Este modelo considera la sentadilla pero excluye el peso muerto.

4. Lognormal incluyendo todo

Modelo:

$$\log(Y_i) \sim \mathcal{N}(\mu_i, \sigma^2) \quad (10)$$

$$\begin{aligned} \mu_i = \beta_0 + \beta_{\text{edad}} \cdot \text{Edad}_i + \beta_{\text{peso}} \cdot \text{Peso}_i + \beta_{\text{squat}} \cdot \text{Squat}_i \\ + \beta_{\text{deadlift}} \cdot \text{Deadlift}_i + \beta_{\text{sexo}}[\text{Sexo}_i] + \beta_{\text{cat}}[\text{Categoría}_i] \end{aligned} \quad (11)$$

$$\hat{Y}_i = \exp(\mu_i) \quad (12)$$

Este modelo considera todas las variables predictoras de la base de datos.

5. Gamma sin squat ni deadlift

Modelo:

$$Y_i \sim \text{Gamma}(\phi, \phi/\mu_i) \quad (13)$$

$$\begin{aligned} \log(\mu_i) = & \beta_0 + \beta_{\text{edad}} \cdot \text{Edad}_i + \beta_{\text{peso}} \cdot \text{Peso}_i \\ & + \beta_{\text{sexo}}[\text{Sexo}_i] + \beta_{\text{cat}}[\text{Categoría}_i] \end{aligned} \quad (14)$$

$$\hat{Y}_i = \mu_i \quad (15)$$

Este modelo excluye los levantamientos de sentadilla y peso muerto.

6. Gamma sin deadlift

Modelo:

$$Y_i \sim \text{Gamma}(\phi, \phi/\mu_i) \quad (16)$$

$$\begin{aligned} \log(\mu_i) = & \beta_0 + \beta_{\text{edad}} \cdot \text{Edad}_i + \beta_{\text{peso}} \cdot \text{Peso}_i + \beta_{\text{squat}} \cdot \text{Squat}_i \\ & + \beta_{\text{sexo}}[\text{Sexo}_i] + \beta_{\text{cat}}[\text{Categoría}_i] \end{aligned} \quad (17)$$

$$\hat{Y}_i = \mu_i \quad (18)$$

Este modelo considera la sentadilla pero excluye el peso muerto.

7. Con interacciones

Modelo:

$$\log(Y_i) \sim \mathcal{N}(\mu_i, \sigma^2) \quad (19)$$

$$\begin{aligned} \mu_i = & \beta_0 + \beta_{\text{edad}} \cdot \text{Edad}_i + \beta_{\text{peso}} \cdot \text{Peso}_i + \beta_{\text{squat}} \cdot \text{Squat}_i + \beta_{\text{sexo}}[\text{Sexo}_i] \\ & + \beta_{\text{cat}}[\text{Categoría}_i] + \beta_{\text{sexo-cat}}[\text{Grupo}_i] + \beta_{\text{sexo-edad}}[\text{Sexo}_i] \cdot \text{Edad}_i \end{aligned} \quad (20)$$

$$\hat{Y}_i = \exp(\mu_i) \quad (21)$$

Este modelo considera dos interacciones: sexo con categoría y sexo con edad. Además, no se considera el peso muerto y, al igual que en los primeros modelos, se considera una distribución Lognormal.

8. Con interacciones y edad al cuadrado

Modelo:

$$\log(Y_i) \sim \mathcal{N}(\mu_i, \sigma^2) \quad (22)$$

$$\begin{aligned} \mu_i = & \beta_0 + \beta_{\text{edad}} \cdot \text{Edad}_i + \beta_{\text{edad}^2} \cdot \text{Edad}_i^2 + \beta_{\text{peso}} \cdot \text{Peso}_i + \beta_{\text{squat}} \cdot \text{Squat}_i \\ & + \beta_{\text{sexo}}[\text{Sexo}_i] + \beta_{\text{cat}}[\text{Categoría}_i] + \beta_{\text{sexo-cat}}[\text{Grupo}_i] + \beta_{\text{sexo-edad}}[\text{Sexo}_i] \cdot \text{Edad}_i \end{aligned} \quad (23)$$

$$\hat{Y}_i = \exp(\mu_i) \quad (24)$$

Este modelo considera las mismas interacciones que antes (y tampoco incluye el peso muerto), pero agrega el término cuadrático de la edad. También se considera una Lognormal.

9. Jerárquico

Modelo:

$$\log(Y_i) \sim \mathcal{N}(\mu_i, \sigma^2) \quad (25)$$

$$\begin{aligned} \mu_i = & \beta_0 + \beta_{\text{edad}} \cdot \text{Edad}_i + \beta_{\text{edad}^2} \cdot \text{Edad}_i^2 + \beta_{\text{peso}} \cdot \text{Peso}_i + \beta_{\text{squat}} \cdot \text{Squat}_i \\ & + \beta_{\text{sexo}}[\text{Sexo}_i] + \beta_{\text{cat}}[\text{Categoría}_i] \end{aligned} \quad (26)$$

$$\hat{Y}_i = \exp(\mu_i) \quad (27)$$

$$\beta_{\text{cat}}[k] \sim \mathcal{N}(\mu_{\text{cat}}, \sigma_{\text{cat}}^2) \quad (28)$$

Este modelo jerarquiza las categorías (raw, wraps, single-ply y multi-ply) en 4 grupos. Además, considera una distribución Lognormal, la edad en forma cuadrática y no considera el peso muerto.

Es importante destacar que, puesto que los modelos incluyen el uso de variables cualitativas, los coeficientes asociados a dichas variables deben incluir alguna restricción de estimabilidad para evitar problemas de multicolinealidad. Así, en este trabajo, se consideró la restricción de suma cero en cada variable cualitativa (sexo y categoría), así como en las interacciones de estas:

$$\sum_{k=1}^K \beta_k = 0.$$

De igual forma, cabe destacar que para todos los modelos se utilizaron distribuciones iniciales de referencia (con baja precisión).

3.2. Comparación de modelos

En la siguiente tabla se muestran los resultados de los valores de DIC y pseudo R^2 que se obtuvieron para cada uno de los nueve modelos. En todos los modelos (salvo el jerárquico) se corrieron (utilizando JAGS) dos cadenas de Markov con 5000 iteraciones, 1000 de burn-in y un adelgazamiento igual a 2. La convergencia de las cadenas se dio de manera adecuada en todos los casos bajo esta configuración, excluyendo el caso del modelo jerárquico. Para este último, se simularon dos cadenas con 1,000,000 de iteraciones, 5000 de burn-in y un adelgazamiento de 50. Sin embargo, ni siquiera con esas especificaciones se logró la convergencia deseada para algunos de los parámetros, además de que el tiempo de cómputo para realizar este proceso fue excesivo (cerca de un día).

Modelo	Pseudo R^2	DIC
Lognormal sin squat ni deadlift	0.6671	77.02
Lognormal sin squat	0.8244	-3838.51
Lognormal sin deadlift	0.8335	-4266.07
Lognormal incluyendo todo	0.8502	-4919.88
Gamma sin squat ni deadlift	0.6672	71587.99
Gamma sin deadlift	0.8335	66056.11
Con interacciones	0.8372	-4425.25
Con interacciones y edad al cuadrado	0.8501	-4872.51
Jerárquico	0.8464	-4700.81

Cuadro 2: Comparación de modelos según Pseudo R^2 y DIC

Cabe aclarar que los DIC entre los 2 modelos que utilizaron una distribución Gamma y los 7 que utilizaron una Lognormal no son comparables. Esto debido a que para estos últimos se les aplicó a los datos la función logaritmo. Por lo cual, el criterio para decidir entre los modelos Gamma y los Lognormal fue la pseudo R^2 , la cual favorece a los modelos Lognormal.

Una vez descartados los modelos Gamma, se utilizaron ambos criterios (DIC y pseudo R^2) para decidir cuáles serían los mejores dos modelos, los cuales resultaron:

- **Lognormal incluyendo todo:** obtuvo el menor DIC de todos los modelos (-4919,88) y el mayor pseudo R^2 (0.8502), lo cual sugiere un excelente equilibrio entre ajuste y simplicidad.
- **Modelo con interacciones y edad al cuadrado:** registró un DIC

ligeramente mayor $(-4872,51)$ y un pseudo R^2 muy parecida (0.8501) , por lo que también se considera competitivo.

4. Desempeño predictivo

Con motivo de evaluar el desempeño predictivo de los mejores modelos, la base de datos, que cuenta con 10856 registros, se segmentó en datos de entrenamiento y datos de prueba. Esta división consistió en un 70 % de la base para entrenamiento y un 30 % para prueba. Una vez obtenidos los dos mejores modelos (con base en los datos de entrenamiento únicamente), se realizaron pruebas para ver cuál de estos predice mejor utilizando los datos de prueba.

4.1. Modelo 1 – Lognormal incluyendo todas las variables

A partir de los resultados mostrados en la Figura 4.1, puede observarse que:

- Los puntos se agrupan fuertemente alrededor de la línea de identidad.
- La nube de puntos está estrechamente alineada, lo que indica alta precisión en las predicciones.
- Hay una leve dispersión en los extremos (especialmente valores muy altos), lo cual es esperable debido a la presencia de valores atípicos, sin embargo, en términos generales, el patrón es altamente lineal y ajustado.




Figura 4: Relación entre valores observados y predichos – Modelo 1

En cuanto a las métricas para medir su capacidad predictiva, el modelo obtuvo una correlación significativamente alta: **0.9002**, y un RMSE relativamente bajo: **22.26**, lo cual, aunado a sus resultados en la sección anterior, lo hacen un modelo preciso y muy confiable.

4.2. Modelo 2 – Con edad al cuadrado e interacciones

Con base en la Figura 4.2, puede verse que:

- Aunque la forma general es ascendente, los puntos presentan una dispersión notoria respecto a la línea de identidad.
- Se observa que el modelo tiende a subestimar valores altos y a sobreestimar algunos valores bajos.

- La dispersión es especialmente evidente en los extremos.




Figura 5: Relación entre valores observados y predichos – Modelo 2

En cuanto a sus métricas, el modelo obtuvo una correlación mucho menor que el modelo anterior: **0.6705**, y un RMSE mayor que el del modelo 1: **42.6471**

4.3. Comparación de modelos

En la siguiente tabla se reportan los valores obtenidos de correlación lineal entre valores reales y predichos (**COR**) y la raíz del error cuadrático medio (**RMSE**) para cada uno de los modelos.

Modelo	COR	RMSE
Lognormal incluyendo todo	0.9002	22.2569
Con interacciones y edad al cuadrado	0.6705	42.6471

Cuadro 3: Comparación de capacidad predictiva entre los dos mejores modelos

Como ya se vio, el modelo *Lognormal incluyendo todo* presenta una correlación significativamente más alta (0.9002 frente a 0.6705) y un RMSE considerablemente más bajo (22.26 frente a 42.65) en comparación con el modelo con interacciones y edad al cuadrado. Esto indica que el primero no solo se ajusta mejor a los datos, sino que también ofrece predicciones más precisas y menos dispersas. En consecuencia, el modelo *Lognormal incluyendo todo* se considera el mejor entre los evaluados, tanto por sus criterios de ajuste vistos en el capítulo previo (DIC y pseudo R^2) como por su capacidad predictiva.

5. Análisis sobre el modelo óptimo

La siguiente tabla muestra los resultados posteriores del Modelo lognormal completo, en el cual la variable respuesta es el logaritmo natural del mejor levantamiento en press de banca ($\log(Y)$). Cada fila corresponde a un parámetro estimado del modelo, mientras que las columnas resumen su distribución posterior obtenida.

La columna “Media” reporta la media posterior de cada parámetro, que puede interpretarse como la mejor estimación puntual bajo la distribución posterior considerando pérdida cuadrática. La columna “SD” corresponde a la desviación estándar posterior, que indica la dispersión asociada a dicha estimación. Las columnas “2.5 %” y “97.5 %” representan los extremos de un intervalo de probabilidad al 95 %.

Las columnas “Rhat” y “n.eff” proporcionan métricas de diagnóstico para evaluar la calidad del muestreo. En particular, “Rhat” (o $\hat{R}$) es un estadístico de convergencia: valores cercanos a 1 indican que las cadenas de Markov han convergido adecuadamente. “n.eff” representa el tamaño efectivo de muestra, es decir, cuántas muestras independientes son equivalentes en términos de información, considerando la autocorrelación de las cadenas.

Es importante recordar que estos coeficientes se interpretan en la escala logarítmica del bench press, por lo que un valor positivo implica un aumento en $\log(Y)$, y un valor negativo implica una disminución. Para obtener el efecto en la escala original, se debe aplicar la transformación exponencial, como se explica en el apartado siguiente.

Cuadro 4: Resumen posterior para el modelo lognormal completo

Parámetro	Media	SD	2.5 %	97.5 %	Rhat	n.eff
β_0	3.501544	0.012104	3.478467	3.525377	1.001106	4000
β_{age}	0.001782	0.000179	0.001439	0.002129	1.002395	910
$\beta_{\text{cat}[1]}$	-0.013109	0.005032	-0.021309	-0.003195	1.000751	4000
$\beta_{\text{cat}[2]}$	-0.036447	0.005299	-0.040973	-0.021045	1.000859	4000
$\beta_{\text{cat}[3]}$	0.043552	0.005792	0.031954	0.054661	1.001702	1600
$\beta_{\text{cat}[4]}$	0.000202	0.011380	-0.022056	0.023050	1.001172	3500
β_{deadlift}	0.002348	0.000089	0.002172	0.002542	1.001182	3500
$\beta_{\text{sex}[1]}$	0.133144	0.001314	0.127080	0.139489	0.999994	4000
$\beta_{\text{sex}[2]}$	-0.133144	0.001314	-0.139428	-0.127080	1.000990	4000
β_{squat}	0.002768	0.000081	0.002606	0.002923	1.001040	4000
β_{weight}	0.001088	0.000121	0.000850	0.001329	1.000764	4000

De los resultados mostrados en la tabla, se observa que la mayoría de los parámetros presentan una buena convergencia, ya que los valores de $\hat{R}$ están muy cercanos a 1 y los tamaños efectivos de muestra ($n.eff$) son altos, lo cual sugiere un muestreo eficiente y estable.

En cuanto a la significancia de los efectos, puede notarse que el parámetro $\beta_{\text{cat}[4]}$ no es estadísticamente significativo, ya que su intervalo de credibilidad al 95% incluye al cero, lo cual indica una alta incertidumbre respecto a si esta categoría difiere del promedio. Un caso similar ocurre con $\beta_{\text{cat}[1]}$, cuyo intervalo está muy próximo al cero. En contraste, parámetros como $\beta_{\text{cat}[2]}$, $\beta_{\text{cat}[3]}$, $\beta_{\text{sexo}[1]}$, $\beta_{\text{sexo}[2]}$, β_{squat} y β_{deadlift} muestran efectos claramente distintos de cero, con intervalos que excluyen al cero completamente, lo que sugiere efectos significativos sobre el logaritmo del bench press. También puede verse que β_{edad} es positivo, lo que indica un efecto positivo (aunque pequeño) de la edad sobre el desempeño.

En general, estos resultados son coherentes con lo observado en el análisis exploratorio: el sexo, el tipo de equipo y el rendimiento en otros levantamientos son factores importantes para predecir el press de banca.

5.1. Interpretación de los coeficientes del modelo lognormal completo

Como ya se mencionó, para interpretar adecuadamente los coeficientes en este modelo, es importante resaltar que las estimaciones fueron hechas en escala logarítmica. El modelo tiene la forma:

$$\log(Y) = \mu = \beta_0 + \beta_j x_j + \dots$$

donde Y es la variable respuesta (en este caso, el mejor levantamiento en press de banca) y x_j es un regresor. En esta formulación, un incremento unitario en x_j implica un incremento de β_j en el logaritmo de Y , es decir:

$$\mu_{\text{nuevo}} = \mu + \beta_j.$$

Aplicando la función exponencial para volver a la escala original, se tiene:

$$Y_{\text{nuevo}} = \exp(\mu + \beta_j) = \exp(\mu) \cdot \exp(\beta_j).$$

Por lo tanto, el cociente entre el nuevo valor esperado de Y y el anterior es:

$$\frac{Y_{\text{nuevo}}}{Y_{\text{viejo}}} = \exp(\beta_j),$$

lo cual implica que el cambio relativo en Y es:

$$\frac{Y_{\text{nuevo}} - Y_{\text{viejo}}}{Y_{\text{viejo}}} = \exp(\beta_j) - 1.$$

Para expresar este cambio en términos porcentuales, basta multiplicar por 100:

$$\text{Cambio relativo (\%)} = (\exp(\beta_j) - 1) \times 100.$$

Esta ecuación permite interpretar los coeficientes estimados en la escala logarítmica como incrementos porcentuales en la escala original.

El modelo *Lognormal incluyendo todo* considera como variable respuesta el logaritmo natural del mejor levantamiento en press de banca, e incluye como predictores la edad, peso corporal, marcas máximas en sentadilla y peso muerto, sexo y categoría de equipo. A las variables categóricas se les agregó la restricción de que su suma sea cero, por lo que sus efectos deben interpretarse como desviaciones respecto al promedio de las categorías.

El intercepto tiene un valor estimado de $\beta_0 \approx 3.50$, lo que implica que el bench press esperado para un atleta promedio en todas las variables es de aproximadamente $\exp(3.50) \approx 33.1$ kg.

En cuanto a los regresores continuos, la edad tiene un coeficiente de $\beta_{\text{edad}} \approx 0.0018$, lo que equivale, una vez hecha la transformación, a un incremento aproximado del 0.18% en el bench press por cada año adicional. El peso corporal tiene un efecto ligeramente menor, con $\beta_{\text{peso}} \approx 0.0011$, es decir, un aumento de

0.11 % por cada kilogramo extra. Ambos efectos son pequeños pero acumulativos, y reflejan la tendencia observada en los datos: los atletas de mayor edad y peso corporal tienden a levantar más.

Las variables de Squat y Deadlift muestran efectos más significativos. Por cada kilogramo adicional en sentadilla, se estima un incremento del 0.28 % en el bench press ($\beta_{\text{squat}} \approx 0.0028$), mientras que cada kilogramo en peso muerto se asocia con un aumento del 0.23 % ($\beta_{\text{deadlift}} \approx 0.0023$). Estos efectos confirman lo que se suponía en el análisis exploratorio: que el rendimiento en sentadilla y peso muerto son buenos predictores del rendimiento en press de banca.

En cuanto a las categorías de equipo, se observa que algunas tienen efectos positivos y otras negativos respecto al promedio. Por ejemplo, una de las categorías (Single-ply) muestra un incremento estimado de 4.5 %, mientras que otras como la categoría Wraps reducen el rendimiento en un 3.6 %. Esto sugiere que el tipo de equipo tiene un impacto técnico importante en el desempeño.

Finalmente, los coeficientes asociados al sexo muestran diferencias claras. Ser hombre ($\beta_{\text{sexo}[1]} = 0.1331$) implica un incremento relativo del 14.2 % en el bench press con respecto al promedio de ambos sexos, mientras que ser mujer ($\beta_{\text{sexo}[2]} = -0.1331$) implica un decremento del 12.6 %. Estas diferencias son consistentes con el análisis exploratorio y con lo esperado dada la fisiología de los atletas.

En conjunto, el modelo refleja adecuadamente los patrones observados en la base de datos: los atletas más pesados y experimentados, con mejor rendimiento en sentadilla y peso muerto, que además pertenecen a ciertas categorías de equipo y son hombres, tienden a tener mejores marcas en press de banca.

Comentarios:

- Los efectos de squat y deadlift son significativos y positivos, lo cual es coherente con el hecho de que son levantamientos físicamente relacionados con el press de banca.
- Las categorías de equipo muestran variabilidad considerable. Algunas como Single-ply (cat[3]) mejoran el rendimiento, otras como Wraps (cat[2]) lo reducen.
- Las diferencias por sexo son importantes: ser hombre se asocia con un incremento significativo en el rendimiento, como se mostró en el análisis exploratorio.
- La edad y el peso corporal tienen efectos positivos pequeños, acumulativos. Reflejan tendencias poblacionales observadas en la base de datos.

Los resultados obtenidos del modelo final no solo permiten realizar predicciones precisas del rendimiento en press de banca, sino que también ofrecen información útil para la toma de decisiones en contextos aplicados. A partir de los coeficientes estimados y su interpretación en la escala original, se pueden derivar las siguientes conclusiones prácticas:

- **Diseño de entrenamientos:** Dado que el rendimiento en bench press está altamente correlacionado con el rendimiento en sentadilla y peso muerto, puede recomendarse el fortalecimiento integral mediante programas que desarrollen de forma complementaria estos otros levantamientos.
- **Estrategias de competencia:** El efecto significativo del tipo de equipamiento sobre el rendimiento sugiere que la decisión de competir en una u otra categoría (Raw, Wraps, etc.) puede tener implicaciones relevantes en el resultado final. Los atletas pueden usar esta información para planificar su participación en categorías donde sus características individuales sean más competitivas.
- **Predicción personalizada:** El modelo permite, a partir de las características observables de un atleta, estimar de manera individualizada su rendimiento esperado en press de banca. Esta funcionalidad puede integrarse en herramientas automatizadas de evaluación de desempeño o planificación deportiva.

6. Conclusión

A lo largo de este trabajo se compararon varios modelos Bayesianos de regresión con el objetivo de predecir el rendimiento en press de banca de atletas de powerlifting a partir de variables personales y de desempeño. El modelo considerado como óptimo, tanto por sus métricas de ajuste (DIC y pseudo R^2) como por su capacidad predictiva, fue aquel que asumió una distribución Lognormal en la variable de interés (Y) e incluyó todas las variables disponibles: edad, peso corporal, tipo de equipo, mejor marca en sentadilla y peso muerto, y sexo.

Los resultados obtenidos muestran una muy buena capacidad predictiva (correlación de 0.90 y RMSE de 22.26 kg), además de efectos coherentes con lo observado empíricamente. Además, se utilizó una codificación centrada por suma cero para las variables categóricas, lo que permitió interpretar los coeficientes como desviaciones respecto al promedio de cada grupo.

En resumen, el modelo desarrollado logra capturar adecuadamente las relaciones clave entre las variables individuales y de desempeño de los atletas,

siendo útil no solo para la predicción, sino también para la comprensión de los factores que más influyen en el rendimiento competitivo en press de banca.

7. Referencias

- Reynolds, J. M., Gordon, T. J., & Robergs, R. A. (2006). Prediction of one repetition maximum strength from multiple repetition maximum testing and anthropometry. *Journal of Strength and Conditioning Research*, 20(3), 584–592. <https://doi.org/10.1519/R-15304.1>
- Bernardo, J. M., & Smith, A. F. M. (1994). *Bayesian theory*. John Wiley & Sons.
- Nieto Barajas, L. E. (s.f.). *Regresión avanzada (con enfoque bayesiano)* [Material de curso]. Instituto Tecnológico Autónomo de México. Recuperado de <http://allman.rhon.itam.mx/lnieto>
- OpenAI. (2025). *ChatGPT* (versión GPT-4). <https://chat.openai.com>