

Proyecto final: Distribución de índices de asociación de especies

Bootstrap paramétrico y Modelo bayesiano

Ximena de la Peña, Andrés Colomar, Orlando Almazán

2026-05-12

Introducción

En el ámbito ecológico un objetivo común es cuantificar la asociación que existe entre dos especies (especie A y especie B). Para ello, suelen realizarse experimentos en los que, en un lugar determinado de interés, se coloca una cámara trampa (es decir, una cámara que se activa al movimiento) para registrar el número de veces en las que dos especies aparecen juntas, aparece una especie pero no la otra o no aparece ninguna. Los resultados de este tipo de experimentos se registran en tablas de Presencia/Ausencia:

	Ausencia especie B	Presencia especie B
Ausencia especie A	x_1	x_2
Presencia especie A	x_3	x_4

En la tabla, x_1 representa el número de veces que no aparece ninguna especie, x_2 el número de veces que aparece la especie B pero no la A, x_3 el número de veces que aparece A pero no B y x_4 el número de veces que aparecen ambas especies a la vez.

Con la finalidad de cuantificar la asociación entre dos especies, diversos ecólogos han desarrollado índices que buscan sintetizar en un número niveles de asociación. A estas cantidades se les conoce en el contexto ecológico como **índices de asociación de especies**. Existe una vasta cantidad de estos índices; en 1982, el autor Zdeněk Hubálek recopiló un total de 43. Cada uno busca, a su manera, describir la asociación entre dos especies; sin embargo, no todos resultan recomendables según el autor. En su artículo, Hubálek propone algunos criterios que buscan determinar si un índice es, o no, efectivo. Entre los índices recomendados, está el **índice de Jaccard**, el cual es ampliamente utilizado en este tipo de estudios. Otro índice también muy utilizado para cuantificar asociación (no solo en el ámbito ecológico) es el **índice de Pearson**, que es el coeficiente de correlación clásico aplicado a dos variables binarias.

Los índices de asociación de especies han sido de gran utilidad para la ecología, pues permiten resumir niveles de asociación en un simple número fácil de interpretar. Sin embargo, a pesar de que los índices son estadísticas, la gran mayoría de estudios ecológicos no reportan medidas de incertidumbre de estas estimaciones. Esto se debe a que, quizás, no cuentan con las herramientas estadísticas para hacerlo. Por ello, este proyecto tiene como finalidad obtener distribuciones muestrales de los índices, con las cuales es posible obtener información adicional a una simple estimación puntual. Como se verá, las metodologías presentadas permitirán obtener estimaciones por regiones (intervalos de confianza), medidas de incertidumbre como error estándar del estimador y sesgo, e incluso será posible obtener distribuciones conjuntas de índices diferentes para estudiar cómo estos se relacionan. En particular, este proyecto se enfocará en los índices de Jaccard y de Pearson.

Marco teórico

Con la finalidad de obtener las distribuciones de los índices, se utilizarán dos metodologías. Para las distribuciones de cada índice (individualmente) se utilizará bootstrap paramétrico. Para obtener la distribución conjunta de ambos índices se usará un modelo bayesiano Multinomial-Dirichlet. Esta última metodología permitirá, además, responder preguntas que involucren a ambos índices a la vez; para esto, se utilizará integración Monte-Carlo.

Índices de asociación

Los índices que se estudiarán en este proyecto son Jaccard y Pearson.

El índice de Jaccard mide la proporción de veces en que ambas especies aparecen a la vez (co-ocurrencia) respecto al total de veces en que al menos aparece una de las especies:

$$J = \frac{x_4}{x_2 + x_3 + x_4}$$

Jaccard toma valores en el intervalo $[0, 1]$, en donde 0 indica la mínima asociación (que se obtiene cuando las especies no aparecen juntas nunca) y 1 indica la mayor asociación posible (que se obtiene cuando las especies siempre aparecen juntas). En la literatura estadística, se considera que valores de J mayores a 0.5 apuntan a una fuerte asociación.

El índice de Pearson mide la asociación entre las dos especies corrigiendo por las frecuencias marginales:

$$\phi = \frac{x_1x_4 - x_2x_3}{\sqrt{(x_1 + x_2)(x_1 + x_3)(x_2 + x_4)(x_3 + x_4)}}$$

Este índice toma valores en el intervalo $[-1, 1]$, en donde 0 indica asociación nula, valores positivos indican que las especies co-ocurren más de lo esperado por azar y valores negativos que co-ocurren menos de lo esperado por azar. Como se mencionó anteriormente, este índice es simplemente la correlación de Pearson aplicado a dos variables binarias.

Bootstrap paramétrico

La finalidad del bootstrap paramétrico es obtener una distribución muestral de la cantidad de interés, en este caso, de los índices de Jaccard y Pearson. La idea es, básicamente, simular muestras de la distribución de la que se suponen provenientes los datos utilizando como parámetros los estimadores (usualmente por máxima verosimilitud) obtenidos con la muestra, para después calcular la cantidad de interés (los índices) con cada una de las muestras. Así, se obtendrá una colección de estimaciones diferentes de la cantidad en cuestión.

En este caso, al ser una tabla de ausencia/presencia resultado de una serie de ensayos en donde solo se cumple una y solo una de las entradas de la tabla, es natural asumir que el vector de datos (x_1, x_2, x_3, x_4) provienen de una distribución Multinomial con 4 posibles resultados (cada una de las celdas de la tabla). Así pues, se asume que el vector aleatorio $X = (X_1, X_2, X_3, X_4)$ sigue una distribución Multinomial:

$$X \sim \text{Multinomial}(n, \theta)$$

donde $\theta = (\theta_1, \theta_2, \theta_3, \theta_4)$ es el vector de probabilidades de cada x_i respectivamente.

Para implementar el bootstrap paramétrico en este caso, primero debe obtenerse un estimador de θ . Para el modelo Multinomial el estimador más directo es el de máxima verosimilitud, que simplemente son las frecuencias relativas de cada celda:

$$\hat{\theta}_i = \frac{x_i}{n}$$

para $i = 1, 2, 3, 4$.

Así, el bootstrap paramétrico consiste en simular una colección de B vectores $\{x^{(s)}\}$ de la distribución $\text{Multinomial}(n, \hat{\theta})$ y calcular para cada una de las simulaciones el valor de los índices. Con esto es posible construir una distribución para cada uno de los índices y, así, estudiar características como su error estándar

$$\widehat{SE}_{boot} = \sqrt{\frac{1}{B} \sum_{b=1}^B (T_b^* - \bar{T}^*)^2}, \quad \bar{T}^* = \frac{1}{B} \sum_{b=1}^B T_b^*$$

o su sesgo:

$$\widehat{\text{sesgo}}_{boot} = \bar{T}^* - T(\hat{\theta})$$

donde T es la estadística en cuestión (índice de Jaccard o Pearson).

Para mayor detalle consultar Battagliola (2026).

Modelo bayesiano Multinomial-Dirichlet

Como se explicó en la sección de bootstrap paramétrico, es natural asumir que los datos en una tabla de ausencia/presencia provienen de una distribución Multinomial. En este modelo se asumirá lo mismo.

En el paradigma bayesiano paramétrico, una vez que se conoce la distribución de la muestra, el objetivo es simplemente describir a los parámetros de dicha distribución. En este caso, al tenerse un modelo Multinomial con parámetros n (fijo) y el vector de probabilidades $\theta = (\theta_1, \theta_2, \theta_3, \theta_4)$, el objetivo es estimar a θ . Para ello, se necesita primero determinar una distribución inicial (*a priori*) que describa las creencias del investigador sobre θ . En la literatura estadística, es común utilizar una inicial Dirichlet, pues ésta resulta conjugada bajo el muestreo Multinomial (i.e. si la distribución inicial es Dirichlet, entonces la distribución posterior (*a posteriori*) también será Dirichlet, aunque con distintos parámetros). Esto resulta conveniente pues asegura que la distribución posterior tiene forma cerrada, por lo que no es necesario emplear técnicas de MCMC para su cálculo. En particular, suele usarse la siguiente distribución inicial para θ :

$$\theta \sim \text{Dir}\left(\frac{1}{2}, \frac{1}{2}, \frac{1}{2}, \frac{1}{2}\right)$$

pues se trata de la inicial mínimo-informativa de Jeffreys (i.e. una distribución inicial que busca incidir lo menos posible en el cálculo de la distribución posterior).

Por medio del Teorema de Bayes, puede obtenerse que la distribución posterior para θ es

$$\theta \mid x \sim \text{Dir}\left(x_1 + \frac{1}{2}, x_2 + \frac{1}{2}, x_3 + \frac{1}{2}, x_4 + \frac{1}{2}\right)$$

es decir, simplemente sumar los resultados de la tabla ausencia/presencia obtenida más $1/2$. Con esta distribución posterior es posible obtener una distribución simulada conjunta para los índices de Jaccard y Pearson de la siguiente forma:

1. Se simulan K muestras de $P(\theta \mid x)$ (notar que se simulan K vectores de longitud 4).
2. Para cada una de esas simulaciones posteriores de θ se calcula el índice deseado. Para ello, se utilizan las expresiones

$$J = \frac{\theta_4}{\theta_2 + \theta_3 + \theta_4}$$

$$\phi = \frac{\theta_1\theta_4 - \theta_2\theta_3}{\sqrt{(\theta_1 + \theta_2)(\theta_1 + \theta_3)(\theta_2 + \theta_4)(\theta_3 + \theta_4)}}$$

que son las definiciones de los índices originales, pero en vez de utilizar los conteos x_i se utilizan las probabilidades θ_i .

3. Con estas colecciones $\{J^{(s)}\}$ y $\{\phi^{(s)}\}$ se grafican los pares $(J^{(s)}, \phi^{(s)})$ para $s = 1, 2, \dots, K$. Con ello se obtiene la distribución conjunta deseada.

Integración Monte Carlo

Aunque los índices de Pearson y Jaccard tienen el objetivo común de medir los niveles de asociación entre las dos especies involucradas, estos no toman valores iguales o valores que indican el mismo nivel de asociación. Por ello, surge naturalmente la pregunta de cómo pueden interpretarse los índices en conjunto. Para responder este cuestionamiento pueden utilizarse técnicas de integración Monte Carlo.

Por ejemplo, una posible manera de determinar si las especies son independientes es plantear el siguiente contraste de hipótesis:

$$H_0 : J < 0.2 \text{ y } \phi \in (-0.15, 0.15)$$

$$H_1 : J \geq 0.2 \text{ ó } \phi \notin (-0.15, 0.15)$$

Ver que H_0 establece un valor de Jaccard muy bajo y un índice de Pearson cercano a 0. Por ello, si se acepta H_0 entonces podría decirse que las especies involucradas son efectivamente independientes (i.e. tienen asociación que puede considerarse nula). Para realizar este contraste simplemente se estima la probabilidad $P(J < 0.2, \phi \in (-0.15, 0.15))$ y se compara con un nivel de significancia $1 - \alpha$. Si la probabilidad es menor que $1 - \alpha$ entonces se tendría que rechazar la hipótesis nula. La estimación de la probabilidad deseada se obtiene con la siguiente estimación Monte Carlo:

$$P(J < 0.2 \text{ y } \phi \in (-0.15, 0.15) \mid x) = \int \mathbf{1}(J(\theta) < 0.2) \cdot \mathbf{1}(\phi(\theta) \in (-0.15, 0.15)) \cdot p(\theta \mid x) d\theta$$

$$\approx \frac{1}{K} \sum_{s=1}^K \mathbf{1}(J(\theta^{(s)}) < 0.2) \cdot \mathbf{1}(\phi(\theta^{(s)}) \in (-0.15, 0.15))$$

Otra pregunta interesante es determinar la probabilidad de que la próxima observación de la tabla sea que ambas especies aparecen juntas, es decir, que al aumentar el tamaño de la muestra a $n + 1$ la observación nueva se sume a x_4 . Para ello, puede utilizarse la probabilidad predictiva posterior, que se define como

$$P(Y_f = y_f \mid x) = \int P(Y_f = y_f \mid \theta) \cdot p(\theta \mid x) d\theta$$

En el contexto del problema, y_f es el vector $(0, 0, 0, 1)$, pues éste cuantifica que la siguiente observación pertenece a la categoría correspondiente a x_4 (mientras que el vector aleatorio X sigue una distribución Multinomial, en donde cada X_i es el conteo de la categoría correspondiente, el vector Y sigue una distribución categórica, cuyos posibles resultados son los vectores canónicos que determinan el resultado del ensayo. Así, se tiene simplemente que X es la suma de todas las Y . Esto es completamente análogo a la relación entre la Bernoulli y la Binomial habitual). Así pues, la probabilidad predictiva posterior queda como

$$P(Y_f = \text{ambas presentes} \mid x) = P(Y_f = (0, 0, 0, 1) \mid x) = \int \theta_4 \cdot p(\theta \mid x) d\theta$$

Y, por tanto, su estimación Monte Carlo es

$$P(Y_f = \text{ambas presentes} \mid x) = E[\theta_4 \mid x] \approx \frac{1}{K} \sum_{s=1}^K \theta_4^{(s)}$$

Con las estimaciones bayesianas también es posible responder preguntas del estilo “¿cuál es la probabilidad de que, con los datos, el índice de Jaccard sea mayor a p y que el índice de Pearson esté en un intervalo (a, b) ?”. Para ello, puede hacerse la siguiente estimación:

$$\begin{aligned} P(J > p, \phi \in (a, b) \mid x) &= \int \mathbf{1}(J(\theta) > p) \cdot \mathbf{1}(\phi(\theta) \in (a, b)) \cdot p(\theta \mid x) d\theta \\ &\approx \frac{1}{K} \sum_{s=1}^K \mathbf{1}(J(\theta^{(s)}) > p) \cdot \mathbf{1}(\phi(\theta^{(s)}) \in (a, b)) \end{aligned}$$

Es decir, simplemente se cuenta cuántas de los K pares simulados cumplen que J es mayor a p y ϕ está en (a, b) , y se divide entre el total de simulaciones K .

En general, la idea de la integración Monte Carlo bayesiana (tomando la distribución posterior) es

$$\mathbb{E}[g(\theta) \mid x] = \int g(\theta) p(\theta \mid x) d\theta \approx \frac{1}{K} \sum_{s=1}^K g(\theta^{(s)})$$

Para mayor detalle, consultar Battagliola (2026).

Metodología y simulación

Los datos que se emplearán estudian a las especies *Nasua Narica* y *Dasyprocta punctata*. Las observaciones se tomaron de un estudio en la reserva nacional mexicana Montes Azules en 2015.

	Ausencia <i>Dasyprocta punctata</i>	Presencia <i>Dasyprocta punctata</i>
Ausencia <i>Nasua narica</i>	$x_1 = 16$	$x_2 = 19$
Presencia <i>Nasua narica</i>	$x_3 = 2$	$x_4 = 3$

Notar que las especies aparecen juntas pocas veces, por lo que podría esperarse que las estimaciones de los índices sean ambas cercanas a 0.

Implementación bootstrap paramétrico

Ya se comentó el procedimiento para generar distribuciones de los índices de Jaccard y Pearson mediante el bootstrap paramétrico. En el siguiente bloque de código se presenta la implementación: primero se definen las funciones de los índices, luego se estiman las probabilidades θ_i para $i \in \{1, 2, 3, 4\}$, posteriormente se generan $B = 100,000$ observaciones del vector $x = (x_1, x_2, x_3, x_4)$ con cada una de las cuales se estiman J y ϕ , y para finalmente con las colecciones de los índices se consiguen las distribuciones bootstrap.

Es importante notar que el índice de Pearson podría tomar valores indefinidos cuando el denominador es 0 o muy cercano a 0. Por ello, es necesario filtrar las observaciones válidas de ese índice. Con la semilla propuesta, se tiene que aproximadamente el 99% de las observaciones totales fueron válidas, por lo que esto no implica un problema para la distribución muestral bootstrap.

```
datos <- c(16,19,2,3) # Datos de la tabla ausencia/presencia observada

# Funciones de Jaccard y Pearson:

jaccard <- function(x) {
  J <- x[4]/(x[2]+x[3]+x[4])
  return(J)
}

pearson <- function(x) {
  num <- x[1]*x[4]-x[2]*x[3]
  den <- sqrt((x[1]+x[2])*(x[1]+x[3])*(x[2]+x[4])*(x[3]+x[4]))
}
```



```

phi <- num/den
return(phi)
}

```

```

set.seed(2026)

```

```

n <- 40 # tamaño de la muestra
theta <- c(datos[1]/n, datos[2]/n, datos[3]/n, datos[4]/n) # estimador MV de theta
B <- 100000 # número de simulaciones bootstrap
sims <- rmultinom(B, size = n, prob = theta) # simulaciones del vector x
jaccard_boot <- apply(sims, 2, jaccard) # aplicar jaccard a x
pearson_boot_pre <- apply(sims, 2, pearson) # aplicar pearson a x
pearson_boot <- pearson_boot_pre[is.finite(pearson_boot_pre)]
length(pearson_boot)/length(pearson_boot_pre)

```

```

[1] 0.99508


```

```

# Histogramas de Jaccard y Pearson bootstrap con media y IC-95%
hist(jaccard_boot, breaks = 30, main = "Distribución bootstrap de Jaccard",
     xlab = "J", col = "steelblue", border = "white",
     xlim = c(0, 1))
abline(v = mean(jaccard_boot), col = "red", lwd = 2, lty = 1)
ic <- quantile(jaccard_boot, c(0.025, 0.975))
abline(v = ic[1], col = "red", lwd = 2, lty = 2)
abline(v = ic[2], col = "red", lwd = 2, lty = 2)
legend(x = 0.55, y = max(hist(jaccard_boot, breaks = 30, plot = FALSE)$counts),
     legend = c(paste("Media =", round(mean(jaccard_boot), 3)),
                paste("IC 95% [", round(ic[1], 3), ",", round(ic[2], 3), "]")),
     col = "red", lty = c(1, 2), lwd = 2, bty = "n")


```

Distribución bootstrap de Jaccard



```
hist(pearson_boot, breaks = 30, main = "Distribución bootstrap de Pearson",
     xlab = "phi", col = "steelblue", border = "white",
     xlim = c(-1, 1))
abline(v = mean(pearson_boot), col = "red", lwd = 2, lty = 1)
ic_p <- quantile(pearson_boot, c(0.025, 0.975))
abline(v = ic_p[1], col = "red", lwd = 2, lty = 2)
abline(v = ic_p[2], col = "red", lwd = 2, lty = 2)
legend("topleft",
      inset = 0.02,
      legend = c(paste("Media =", round(mean(pearson_boot), 3)),
                 paste0("IC 95% [", round(ic_p[1], 3), ", ", round(ic_p[2], 3), "]")),
      col = "red", lty = c(1, 2), lwd = 2, bty = "n")
```

Distribución bootstrap de Pearson



Con la información de la distribución bootstrap puede obtenerse el error estándar y el sesgo para ambos índices con las fórmulas descritas en el marco teórico.

```
# Errores estándar
se_boot_jaccard <- sd(jaccard_boot)
se_boot_pearson <- sd(pearson_boot)
cat("Error estándar bootstrap de Jaccard: ", se_boot_jaccard)
```

Error estándar bootstrap de Jaccard: 0.06807162

```
cat("Error estándar bootstrap de Pearson: ", se_boot_pearson)
```

Error estándar bootstrap de Pearson: 0.1578574

```
# Sesgo
sesgo_boot_jaccard <- mean(jaccard_boot) - jaccard(datos)
sesgo_boot_pearson <- mean(pearson_boot) - pearson(datos)
cat("Sesgo bootstrap de Jaccard: ", sesgo_boot_jaccard)
```

Sesgo bootstrap de Jaccard: -2.504076e-05

```
cat("Sesgo bootstrap de Pearson: ", sesgo_boot_pearson)
```

Sesgo bootstrap de Pearson: -0.0008182797

Con el error estándar y el sesgo calculado puede determinarse si el sesgo es despreciable. A continuación se implementa la regla de dedo de Efron y Tibshirani, la cual establece que el sesgo es despreciable si se cumple que

$$|\widehat{se\hat{go}}_{boot}| < 0.25\widehat{se}_{boot}$$

```
# Regla de dedo de Efron (si TRUE entonces el sesgo es despreciable):
abs(sesgo_boot_jaccard) < 0.25*se_boot_jaccard
```

```
[1] TRUE
```

```
abs(sesgo_boot_pearson) < 0.25*se_boot_pearson
```

```
[1] TRUE
```

Implementación modelo bayesiano Multinomial-Dirichlet

Para simular vectores de la distribución Dirichlet puede emplearse la siguiente función con base en la distribución Gamma:

```
# Función para generar Dirichlet con Gammas:
simulate_dirichlet <- function(alpha, K) {
  M <- length(alpha)
  samples <- matrix(NA, nrow = K, ncol = M)
  for (k in 1:K) {
    gammas <- rgamma(M, shape = alpha, rate = 1)
    samples[k, ] <- gammas / sum(gammas)
  }
  return(samples)
}
```

El código siguiente genera K muestras simuladas del vector θ . Primero se especifican los parámetros iniciales y posteriores de la distribución Dirichlet de θ .

```
set.seed(2026)

K <- 100000 # número de simulaciones de theta

# Procedimiento a priori:
```

```

alpha_priori <- c(0.5,0.5,0.5,0.5) # parámetros iniciales
theta_samples_priori <- simulate_dirichlet(alpha_priori, K) # simulaciones

# Procedimiento a posteriori
alpha_posteriori <- alpha_priori + datos # parámetros a posteriori
theta_samples_posteriori <- simulate_dirichlet(alpha_posteriori, K) # simulaciones

```

Aunque las únicas muestras “importantes” son las posteriores, se generan también las muestras a priori de θ con la finalidad de graficar también la distribución inicial conjunta de ambos índices para ver el impacto de los datos en la distribución posterior.

Una vez que se tienen estas simulaciones de θ se calculan las simulaciones de J y ϕ con las fórmulas especificadas en el Marco teórico. Posteriormente puede graficarse la distribución conjunta $P(\phi, J)$.


```

jaccard_prior <- apply(theta_samples_priori, 1, jaccard)
pearson_prior <- apply(theta_samples_priori, 1, pearson)
jaccard_post <- apply(theta_samples_posteriori, 1, jaccard)
pearson_post <- apply(theta_samples_posteriori, 1, pearson)

# Gráfica conjunta:
valid_post <- is.finite(jaccard_post) & is.finite(pearson_post)
plot(pearson_post[valid_post], jaccard_post[valid_post],
     pch = ".", col = "blue",
     xlim = c(-1, 1), ylim = c(0, 1),
     xlab = "Pearson (phi)", ylab = "Jaccard (J)",
     main = "Distribución conjunta P(phi, J)")
valid_prior <- is.finite(jaccard_prior) & is.finite(pearson_prior)
points(pearson_prior[valid_prior], jaccard_prior[valid_prior],
       pch = ".", col = rgb(0.5, 0.5, 0.5, 0.1))
legend("topright", inset = 0.02,
       legend = c("A priori", "A posteriori"),
       col = c(rgb(0.5, 0.5, 0.5), rgb(0.1, 0.4, 0.8)),
       pch = 16, bty = "n")

```

Distribución conjunta P(phi, J)



Implementación de métodos Monte Carlo

Contraste de la hipótesis de independencia de especies

Para llevar a cabo el contraste de las hipótesis

$$H_0 : J < 0.2 \text{ y } \phi \in (-0.15, 0.15)$$

$$H_1 : J \geq 0.2 \text{ ó } \phi \notin (-0.15, 0.15)$$

se necesita calcular la probabilidad $P(J < 0.2, \phi \in (-0.15, 0.15))$. Para ello se usa el estimador Monte Carlo

$$\hat{P}(J < 0.2, \phi \in (-0.15, 0.15)) = \frac{1}{K} \sum_{s=1}^K \mathbf{1}(J(\theta^{(s)}) < 0.2) \cdot \mathbf{1}(\phi(\theta^{(s)}) \in (-0.15, 0.15))$$

Considérese un nivel de significancia $\alpha = 0.05$, por lo cual si $\hat{P}$ es menor a 0.95 entonces se rechaza H_0 .

```
# Como pearson a veces no está definido primero deben filtrarse las
# simulaciones válidas:
valid_post <- is.finite(jaccard_post) & is.finite(pearson_post)
J <- jaccard_post[valid_post]
P <- pearson_post[valid_post]
```

```
# Estimación de la probabilidad deseada:
# Simplemente cuenta las observaciones (J,phi) que cumplen la condición de H0
# y la divide entre el número total de simulaciones válidas:
p_nula <- mean(J < 0.2 & P > -0.15 & P < 0.15)

cat("P(J < 0.2 y phi  (-0.15, 0.15) | x):", round(p_nula, 4), "\n")
```

P(J < 0.2 y phi (-0.15, 0.15) | x): 0.6304

```
if (p_nula >= 0.95) {
  cat("→ Se puede afirmar asociación nula al 95%\n")
} else {
  cat("→ No se puede afirmar asociación nula al 95%\n")
}
```

→ No se puede afirmar asociación nula al 95%

Probabilidad predictiva de la próxima observación

En el Marco teórico se estableció que el estimador de la probabilidad de que la próxima observación sea que ambas especies estén presentes es

$$\hat{P}(Y_f = \text{ambas presentes} \mid x) = \frac{1}{K} \sum_{s=1}^K \theta_4^{(s)}$$

```
p_predictiva <- mean(theta_samples_posteriori[, 4])
cat("P(próxima obs = ambas presentes | datos):", round(p_predictiva, 4), "\n")
```

P(próxima obs = ambas presentes | datos): 0.0834

Además, es posible obtener un intervalo de credibilidad con los cuantiles de la distribución posterior de θ_4 :

```
theta4_post <- theta_samples_posteriori[, 4]
ic_pred <- quantile(theta4_post, c(0.025, 0.975))

hist(theta4_post, breaks = 60, freq = FALSE,
      col = "steelblue", border = "white",
```

```


main = expression("Distribución posterior de " * theta[4]),
xlab = expression(theta[4]), ylab = "Densidad",
xlim = c(0, 1))

abline(v = mean(theta4_post), col = "red", lwd = 2, lty = 1)
abline(v = ic_pred[1], col = "red", lwd = 2, lty = 2)
abline(v = ic_pred[2], col = "red", lwd = 2, lty = 2)

legend("topright", inset = 0.02,
      legend = c(paste("Media =", round(mean(theta4_post), 4)),
                  paste0("IC 95% [", round(ic_pred[1], 4), ", ", round(ic_pred[2], 4), "]")),
      col = "red", lty = c(1, 2), lwd = 2, bty = "n")

```

Distribución posterior de θ_4



Probabilidades conjuntas

Suponga que se desea saber la probabilidad de que con los datos observados $J > 0.3$ y $\phi \in (0.2, 0.5)$. Es decir, se busca estimar la probabilidad

$$P(J > 0.3, \phi \in (0.2, 0.5) \mid x) = \int \mathbf{1}(J(\theta) > 0.3) \cdot \mathbf{1}(\phi(\theta) \in (0.2, 0.5)) \cdot p(\theta \mid x) d\theta$$

Se usa el estimador

$$\hat{P}(J > 0.3, \phi \in (0.2, 0.5)) = \frac{1}{K} \sum_{s=1}^K \mathbf{1}(J(\theta^{(s)}) > 0.3) \cdot \mathbf{1}(\phi(\theta^{(s)}) \in (0.2, 0.5))$$


```
p_conjunta <- mean(J > 0.3 & P > 0.2 & P < 0.5)
cat("P(J>0.3, phi en (0.2, 0.5) | datos):", round(p_conjunta, 4), "\n")
```

P(J>0.3, phi en (0.2, 0.5) | datos): 0.0192

Probabilidades marginales

Además de obtener probabilidades conjuntas, también es posible obtener probabilidades marginales. Por ejemplo, suponga que se desea saber la probabilidad de que, con los datos, $\phi < 0$ (es decir, que la asociación entre las especies sea negativa).

```
p_phineg <- mean(pearson_post<0)
cat("P(phi<0 | datos):", round(p_phineg, 4), "\n")
```

P(phi<0 | datos): 0.4106

Resultados e interpretación

Bootstrap paramétrico

Con la distribución muestral bootstrap se obtuvieron los siguientes resultados:

Índice	Media	IC 95%	Sesgo bootstrap	SE bootstrap
Jaccard (J)	0.1250	(0.0000, 0.2730)	0.0000	0.0681
Pearson (ϕ)	0.0371	(-0.2804, 0.3250)	-0.0010	0.1578

Como se anticipaba, ambos índices de asociación apuntan hacia un nivel de asociación bajo entre las especies *Nasua Narica* y *Dasyprocta punctata*. Tanto el índice de Jaccard como el de Pearson son cercanos a 0, el nivel mínimo de asociación. Es importante mencionar también que los intervalos de confianza percentiles confirman una asociación baja al estar definidos en valores cercanos a 0.

Algo a destacar es la forma de las distribuciones muestrales bootstrap. Observar que la de Jaccard es asimétrica, por lo que el intervalo de confianza percentil es más fiable que un posible intervalo construido con una aproximación Normal. Por otra parte, la distribución del índice de Pearson es relativamente simétrica y está centrada en 0. Esto puede ofrecer criterios para afirmar que dicho índice es 0.

En cuanto a la calidad de las estimaciones, observar que el sesgo bootstrap de ambos índices es prácticamente 0, por lo que se tratan de estimaciones insesgadas; esto se confirma al aplicar la regla de dedo de Efron y Tibshirani, en la cual se establece que el sesgo es despreciable. Además, el error estándar bootstrap de ambas estimaciones es relativamente bajo, aunque no despreciable. Notar que sobre todo en Pearson este error no es del todo bajo, por lo que dicha estimación puede tener un ligero error.

Estos resultados indican que las especies están débilmente asociadas.

Modelo bayesiano

La forma de la distribución inicial conjunta entre Pearson y Jaccard refleja la relación factible entre los índices. Observar que esta relación no es estrictamente lineal, sino que forma una especie de banda en forma de cilindro que se extiende en los extremos de la gráfica. Notar que cuando $J = 0$ se tendrá casi siempre una asociación negativa según Pearson. Por otro lado, para valores de Jaccard cercanos a 1 lo más común es observar valores de Pearson positivos.

La distribución posterior conjunta mostrada en azul muestra una mayor concentración que la distribución inicial. Esto es siempre de esperarse pues con la información proporcionada por los datos se espera que la incertidumbre de lo que se busca estimar se reduzca. Observe

que esta distribución posterior se concentra alrededor del 0 en ϕ y alrededor de 0.15 en J . Notar además que el rango aproximado de los índices posibles (con los datos observados) es $(-0.5, 0.5)$ para Pearson y $(0, 0.4)$ para Jaccard. Estos resultados bayesianos concuerdan con lo estimado por el bootstrap paramétrico presentado anteriormente.

Es importante observar que la nube de puntos de la distribución posterior no está muy concentrada. Esto refleja que 40 observaciones quizá resulte insuficiente para hacer estimaciones completamente confiables, i.e. las estimaciones tienen una incertidumbre no despreciable. Este resultado también concuerda con lo obtenido en el bootstrap.

En términos ecológicos, con la distribución conjunta posterior podría decirse que las especies no muestran fuerte evidencia ni de atracción mutua ni de repulsión. Esto puede interpretarse que las especies *Nasua Narica* y *Dasypsecta punctata*, en Montes Azules, ni se benefician mutuamente de estar juntas, ni compiten por recursos en un hábitat. Por lo que podría decirse que estas especies conviven de forma aleatoria. Sin embargo, al ser una distribución relativamente dispersa no puede asegurarse con total certeza que las especies tengan asociación nula.

Métodos Monte Carlo

Contraste de hipótesis

Según lo estimado, si se toma en cuenta una significancia de $\alpha = 0.05$ debe rechazarse la hipótesis de independencia entre las especies (con la información de la muestra). Esto es interesante y refleja la incertidumbre vista en la distribución posterior conjunta. A pesar de que las estimaciones marginales puntuales obtenidas con bootstrap indican una asociación muy baja con ambos índices, debido a la incertidumbre de la distribución conjunta debe rechazarse H_0 . Observe que la credibilidad de que con los datos se obtenga que el índice esté en el rango conjunto establecido es aproximadamente del 63%, por lo que no es posible afirmar contundentemente que las especies sean independientes. Para ello, haría falta quizá una muestra más grande que concentre más la distribución posterior.

Probabilidad predictiva

Con las muestras bayesianas posteriores se obtuvo la estimación

$$\hat{P}(Y_f = \text{ambas presentes} \mid x) = 0.0834$$

con un intervalo de credibilidad al 95% (0.0210, 0.1832).

Así pues, la probabilidad de que la observación 41 sea que ambas especies estén presentes es relativamente baja (cerca al 8.3%). Este resultado es coherente con los datos observados, pues la celda correspondiente a x_4 es 3, que, considerando el tamaño de la muestra, es un número pequeño.

Este resultado, lejos de reflejar que las especies están correlacionadas negativamente (por Pearson) más bien refleja el hecho de que la especie *Nasua Narica* aparece poco (solo 5 veces de los 40 registros, es decir, aparece solo un 12.5% de las veces). Por ende, como *Nasua Narica* aparece poco entonces el evento en donde ambas especies aparecen juntas es poco probable.

Probabilidades conjuntas y marginales

Simplemente como ejemplo de las posibles aplicaciones que pueden hacerse considerando la distribución conjunta, se estimaron las siguientes cantidades:

- $\hat{P}(J > 0.3, \phi \in (0.2, 0.5)) = 0.0192$. Este resultado puede interpretarse como que la probabilidad de que, con los datos, la asociación sea considerable (considerando a Pearson y Jaccard) es relativamente baja (cerca del 2%).
- $\hat{P}(\phi < 0) = 0.4106$. Este resultado se interpreta simplemente como que la probabilidad de que, con los datos, el índice de Pearson sea negativo es relativamente alta (41% aproximadamente). Esto se debe a que la distribución posterior de ϕ está centrada cerca de 0 y es casi simétrica, por lo que esta estimación es coherente con lo observado.

Conclusión

Los índices de asociación han sido durante muchos años muy importante para los estudios ecológicos cuyo objetivo es cuantificar la asociación entre dos especies en particular. Sin embargo, en la gran mayoría de estudios solo se reporta el valor puntual del índice que éste arroja al evaluarlo con los datos observados. Con las metodologías presentadas fue posible obtener distribuciones de estos índices para medir la calidad de la estimación dada. Esto es de suma importancia no solo en el contexto ecológico sino en todos los estudios en donde se reporten estadísticas.

Así pues, con los métodos vistos se obtuvieron las distribuciones de los índices de Pearson y de Jaccard. Esto permitió observar que las estimaciones tienen una incertidumbre considerable, por lo que no es posible asegurar la independencia de las especies *Nasua Narica* y *Dasyprocta punctata* en la reserva Montes Azules, a pesar de que los valores puntuales indican que las especies tienen una asociación prácticamente nula. El hecho de que no se pueda asegurar la independencia se debe no a que las estimaciones puntuales “ingenuas” sean incompatibles con las obtenidas mediante la simulación, sino que se debe a la incertidumbre de las estimaciones. Esta incertidumbre se pudo observar en los errores estándar bootstrap y en la forma de la distribución posterior conjunta bayesiana, que es medianamente dispersa.

Una limitación del estudio realizado es que no se consideraron más índices. Como se mencionaba, hay por lo menos 43 índices que han sido utilizados en estudios ecológicos de este tipo. Sin embargo, por cuestiones de longitud, no fue posible considerar muchos índices. Un posible estudio posterior sería realizar un análisis de índices para determinar cuáles pares de estos tienen sinergia entre sí dependiendo del objetivo del estudio en cuestión. Sin embargo, es importante mencionar que los métodos propuestos en este proyecto se aplican de manera prácticamente idéntica para otros índices (cambiando solamente las fórmulas de los índices). Otro posible trabajo futuro en esta línea de investigación podría ser establecer contrastes estadísticos que tomen en cuenta solo los datos de la tabla sin considerar el contexto ecológico y comparar si estos contrastes estadísticos coinciden con la noción de dependencia proporcionada por los índices.

Referencias

- De Cáceres, M., & Legendre, P. (2009). Associations between species and groups of sites: indices and statistical inference. *Ecology*, 90(12), 3566–3574.
- Hubálek, Z. (1982). Coefficients of association and similarity, based on binary (presence–absence) data: an evaluation. *Biological Reviews*, 57(3), 669–689.
- Mendoza, M., Mendoza, E., & Gutiérrez-Peña, E. (2024). Statistical analysis of species association indices. *Journal of Tropical Ecology*, 40(e12), 1–8. doi:10.1017/S0266467424000105
- Battagliola, L. (2026). Notas del curso de Simulación.